

Analysis für Informatik 2 | An2I

Zusammenfassung

INHALTSVERZEICHNIS

1. Taylorpolynom	2
1.1. Berechnung	2
1.2. Generalisierung	3
1.3. Taylorreihe	4
1.4. Fehlerabschätzungen	4
1.4.1. Anwendung	5
2. Grenzwerte	6
2.1. Eigentliche Grenzwerte im Unendlichen	6
2.2. Eigentliche Grenzwerte im Endlichen	7
2.2.1. Einseitige Grenzwerte	8
2.3. Rechenregeln	8
2.4. Uneigentliche Grenzwerte im Endlichen	9
2.5. Satz von Bernoulli und l'Hospital	10
2.6. Rechnen mit unendlich grossen «Zahlen»	11
3. Ableitung	11
4. Interpolation	11
4.1. Methode der kleinsten Quadrate (RSS)	13
4.2. Lineare Regression	14
4.2.1. Generalisierung	16
4.3. Overfitting	17
4.4. Wahl der Basisfunktion	17

1. TAYLORPOLYNOM

- Approximation von Funktionen durch Polynome
- Innerhalb vom Konvergenzradius sind Funktionen immer durch unendliche Polynome perfekt approximierbar

1.1. BERECHNUNG

Jede Ableitung ist die nächste Unbekannte:

$$\begin{aligned}
 p(x) &= a_0 + a_1(x - x_0) + a_2(x - x_0)^2 + a_3(x - x_0)^3 \\
 p'(x) &= 0 + a_1 \quad + a_2 2(x - x_0) + a_3 3(x - x_0)^2 \\
 p''(x) &= 0 + 0 \quad + a_2 2 \quad + a_3 6(x - x_0) \\
 p'''(x) &= 0 + 0 \quad + 0 \quad + a_3 6 \\
 p''''(x) &= 0 + 0 \quad + 0 \quad + 0
 \end{aligned}$$

x_0 einsetzen:

$$\begin{aligned}
 p(x_0) &= a_0 + \cancel{a_1(x_0 - x_0)} + \cancel{a_2(x_0 - x_0)^2} + \cancel{a_3(x_0 - x_0)^3} = a_0 \\
 p'(x_0) &= 0 + a_1 \quad + \cancel{a_2 2(x_0 - x_0)} + \cancel{a_3 3(x_0 - x_0)^2} = a_1 \cdot 1 \\
 p''(x_0) &= 0 + 0 \quad + a_2 2 \quad + \cancel{a_3 6(x_0 - x_0)} = a_2 \cdot 2 \cdot 1 \\
 p'''(x_0) &= 0 + 0 \quad + 0 \quad + a_3 6 = a_3 \cdot 3 \cdot 2 \cdot 1 \\
 p''''(x_0) &= 0 + 0 \quad + 0 \quad + 0
 \end{aligned}$$

Somit:

$$\begin{aligned}
 p^{(n)}(x_0) &= a_n \cdot n! \\
 \Leftrightarrow a_n &= \frac{p^{(n)}(x_0)}{n!}
 \end{aligned}$$

Beispiel 1

$$p(x) = 3x^3 - 2x + 5$$

$$\text{Entwicklungspunkt EWP} = x_0 = 1$$

NR:

$$p(x) = 3x^3 - 2x + 5$$

$$p'(x) = 9x^2 - 2$$

Linearisierung:

$$p(x_0) = 3x_0^3 - 2x_0 + 5 = 3 - 2 + 5 = 6$$

$$p'(x_0) = 9x_0^2 - 2 = 9 - 2 = 7$$

Ergo: $p(x) \approx 6 + 7(x - 1)$ = Taylor-Polynom von Grad 1

Taylor-Polynom von Grad 3: $p(x) \approx \underbrace{6 + 7(x - 1)}_{\text{Linearisierung}} + ?(x - 1)^2 + ?(x - 1)^3$

$$\begin{aligned}
p(x_0) &= 3x_0^3 - 2x_0^5 = 3 - 2 + 5 = 6 = a_0 && \Rightarrow a_0 = 6 \\
p'(x_0) &= 9x_0^2 - 2 = 9 - 2 = 7 = 1 \cdot a_1 && \Rightarrow a_1 = 7 \\
p''(x_0) &= 18x_0 = 18 = 1 \cdot 2 \cdot a_2 && \Rightarrow a_2 = 9 \\
p'''(x_0) &= 18 = 1 \cdot 2 \cdot 3 \cdot a_3 && \Rightarrow a_3 = 3
\end{aligned}$$

Gibt uns:

$$p(x) \approx 6 + 7(x - 1) + 9(x - 1)^2 + 3(x - 1)^3$$

1.2. GENERALISIERUNG

Für ein Polynom $p(x)$ vom Grad n und einem Entwicklungspunkt x_0 gilt:


$$p(x) = \sum_{k=0}^n \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k$$

Für eine Funktion $f(x)$ und einen EWP x_0 heisst

$$\sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$

Taylor-Polynom von Grad n für $f(x)$ um EWP x_0

Beispiel 2: $f(x) = \sin(x)$, $x_0 = 0$



Beobachtungen 1

- 1.1. In der Nähe des EWP x_0 gilt $f(x) \approx \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$
- 1.2. Je grösser n ist, umso kleiner ist der Unterschied der beiden Seiten

1.3. Der Unterschied ist umso kleiner, je näher x bei x_0 liegt

Beispiel 3: $f(x) = e^x$, EWP $x_0 = 0$

Gesucht: Taylor-Polynom vom Grad n

$$f(x) = e^x \Rightarrow f(0) = e^0 = 1$$

$$f'(x) = e^x \Rightarrow f'(0) = e^0 = 1$$

$$f''(x) = e^x \Rightarrow f''(0) = e^0 = 1$$

$$f^{(n)}(x) = e^x \Rightarrow f^{(n)}(0) = e^0 = 1$$

$$\Rightarrow e^x \approx \sum_{k=0}^n \frac{1}{k!} ((x-0)^k) \Leftrightarrow e^x \approx \sum_{k=0}^n \frac{1}{k!} (x^k)$$

1.3. TAYLORREIHE

Die Taylor-Reihe von $f(x)$ um den Entwicklungspunkt x_0 ist

$$\sum_{k=0}^{\infty} \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k$$

Es gibt eine Zahl $R > 0$, so dass $f(x) = \sum_{k=0}^{\infty} \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k$, für $|x - x_0| < R$
(R = Konvergenzradius)

1.4. FEHLERABSCHÄTZUNGEN

Wie weit liegt der vom Taylor-Polynom mit Grad n vorhergesagte Funktionswert vom richtigen Wert entfernt?


$$\begin{aligned} \text{Rechenfehler} &= \left| f(x) - \sum_{k=0}^n \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k \right| \\ &\approx \left| \sum_{k=0}^{n+1} \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k - \sum_{k=0}^n \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k \right| \\ &= \left| \frac{f^{(n+1)}(x_0)}{(n+1)!} (x - x_0)^{n+1} \right| \end{aligned}$$

Es gibt eine Zahl $\xi \in [x_0; x]$, so dass

$$\begin{aligned} \text{Rechenfehler} &= \left| f(x) - \sum_{k=0}^n \frac{p^{(k)}(x_0)}{k!} (x - x_0)^k \right| \\ &= \left| \frac{f^{(n+1)}(\xi)}{(n+1)!} (x - x_0)^{n+1} \right| \\ &= \frac{|f^{(n+1)}(\xi)|}{(n+1)!} |x - x_0|^{n+1} \end{aligned}$$

$$\leq \frac{\max_{\xi \in [x_0; x]} |f^{(n+1)}(\xi)|}{(n+1)!} |x - x_0|^{n+1}$$

(Falls $f(x)$ nicht berechenbar)



1.4.1. Anwendung

Gegeben: $f(x)$, Intervall $I = [a; b]$, max. Rechenfehler Δ

Gesucht: Grad des Taylor-Polynoms n , Entwicklungspunkt x_0

Antwort: $x_0 = \frac{a+b}{2} \Rightarrow |x - x_0| \leq \frac{b-a}{2}$

Bestimme n :

$$\frac{\max_{\xi \in [x_0; x]} |f^{(n+1)}(\xi)|}{(n+1)!} |x - x_0|^{n+1} \stackrel{!}{\leq} \Delta$$

$$< \frac{m}{(n+1)!} \left(\frac{b-a}{2} \right)^{n+1} \quad \left| m > \max_{\xi \in [x_0; x]} |f^{(n+1)}(\xi)| \right.$$

Beispiel 4 : Gegeben: $f(x) = \sin(x)$ auf $I = [0; \pi]$ durch Taylor-Polynom mit Rechenfehler $\Delta = 0.01$
 berechnet werde: $x_0 = \frac{\pi}{2}$

$$\begin{aligned} f(x) &= \sin(x) \\ f'(x) &= \cos(x) \\ f''(x) &= -\sin(x) \\ f'''(x) &= -\cos(x) \\ f^{(4)}(x) &= \sin(x) \\ &\vdots \\ f^{(n)}(x) &= \sin(x) \\ \Rightarrow |f^{(n+1)}(x)| &= \begin{cases} |\sin(x)| \\ |\cos(x)| \end{cases} \leq 1 \\ \Rightarrow m &= 1 \end{aligned}$$

n muss so gewählt werden, dass

$$\frac{1}{(n+1)!} \left(\frac{\pi}{2} \right)^{n+1} \leq 0.01$$

1.4.1.1. Rechenregeln Fakultät

$$\frac{n!}{(n-1)!} = n \cdot (n-1)$$

$$\frac{n!}{(n-2)!} = n \cdot (n-1) \cdot (n-2)$$

$$n! \cdot (n+1)! = (n+1)!$$

2. GRENZWERTE

2.1. EIGENTLICHE GRENZWERTE IM UNENDLICHEN

Die Zahl $F \in \mathbb{R}$ heisst Grenzwert von $f(x)$ für x gegen ∞ , wenn für alle $\varepsilon > 0$ eine «Grenze» X existiert, so dass für alle «noch grössere Zahlen» $x > X$ gilt: $|f(x) - F| < \varepsilon$.

$$\forall \varepsilon \in \mathbb{R} : \varepsilon > 0 \wedge |f(x) - F| < \varepsilon$$


$$\Rightarrow \lim_{x \rightarrow \infty} f(x) = F \Leftrightarrow f(x) \xrightarrow{x \rightarrow \infty} F$$

Beobachtungen 2

$$2.1. \quad \forall x > X : |f(x) - F| < \varepsilon \Rightarrow \lim_{x \rightarrow \infty} f(x) = F$$

$$2.2. \quad \forall x < X : |f(x) - F| < \varepsilon \Rightarrow \lim_{x \rightarrow -\infty} f(x) = F$$

Beispiel 5: $f(x) = \arctan(x)$, $F = \frac{\pi}{2}$, $X = \tan\left(\frac{\pi}{2} - \varepsilon\right)$



$$\lim_{x \rightarrow \infty} \arctan(x) = \frac{\pi}{2}$$

$$\lim_{x \rightarrow -\infty} \arctan(x) = -\frac{\pi}{2}$$

Beobachtungen 3

$$3.1. \quad |x| - F \text{ wird kleiner, wenn } x \text{ grösser wird}$$

- 3.2. Falls ε bei F anders gewählt wird, verschiebt sich X aber die Funktionswerte bleiben im Bereich $|f(x) - F|$
- 3.3. Falls F anders gewählt wird, kommen Funktionswerte ausserhalb vom erlaubten Bereich

Bei $\lim \rightarrow \infty$ kann man alle Terme, die sich nach 0 bewegen, ignorieren.


Beispiel 6 : $\lim_{x \rightarrow \infty} \frac{2x + 3}{x^2 - 3x + 5}$

$$\begin{aligned} & \lim_{x \rightarrow \infty} \frac{2x + 3}{x^2 - 3x + 5} \\ &= \lim_{x \rightarrow \infty} \frac{x \left(2 + \frac{3}{x} \right)}{x^2 \left(1 - \frac{3}{x} + \frac{5}{x^2} \right)} \\ &= \lim_{x \rightarrow \infty} \frac{1}{x} \frac{\left(2 + \frac{3}{x} \right)}{1 - \frac{3}{x} + \frac{5}{x^2}} \\ &= 0 \cdot \frac{2}{1} = 0 \end{aligned}$$

2.2. EIGENTLICHE GRENZWERTE IM ENDLICHEN


$\lim_{x \rightarrow q} f(x)$ = Wert der stetigen Fortsetzung von $f|_{D_f \setminus q}(x)$ an der Stelle $x = q$. f ist stetig in $q \Leftrightarrow \lim_{x \rightarrow q} f(x) = f(q)$

Beispiel 7 : $f(x) = \frac{x^3 + 3x^2 - 6x - 8}{x - 2}$



Beispiel 8: $\lim_{x \rightarrow 0} \text{sig}^2(x) = 1$

$$\text{sig} : \begin{cases} \mathbb{R} \rightarrow \mathbb{R} \\ x \mapsto \begin{cases} +1 & \text{für } x > 0 \\ 0 & \text{für } x = 0 \\ -1 & \text{für } x < 0 \end{cases} \end{cases}$$



Beobachtungen 4

- 4.1. $\text{sig}^2(x)$ ist an der Stelle 0 nicht stetig, denn $\lim_{x \rightarrow 0} f(x) \neq f(0)$
- 4.2. $\lim_{x \rightarrow 0} \text{sig}^2(x) = 1$, obwohl der Funktionswert bei $x = 0$ nicht 1 sondern $y = 0$ ist.

2.2.1. Einseitige Grenzwerte


$\lim_{x \rightarrow 0} \text{sig}(x)$ existiert nicht. Das ändert sich aber, wenn man den Definitionsbereich auf $\mathbb{R}^+$ oder $\mathbb{R}^-$ einschränkt.

Rechtsseitiger Grenzwert

$$\lim_{\substack{x \rightarrow 0 \\ x > 0}} \text{sig}(x) = \lim_{x \rightarrow 0^+} \text{sig}(x) = 1$$

Linksseitiger Grenzwert

$$\lim_{\substack{x \rightarrow 0 \\ x < 0}} \text{sig}(x) = \lim_{x \rightarrow 0^-} \text{sig}(x) = -1$$



Beobachtungen 5

- 5.1. Wenn sich der rechtsseitige und linksseitige Grenzwert unterscheiden, existiert der beidseitige Grenzwert nicht.

2.3. RECHENREGELN

Seien $f(x)$ und $g(x)$ zwei Funktionen und $q \in \mathbb{R} \cup \{-\infty, \infty\}$ eine beliebige reelle Zahl oder Unendlich.

$$\lim_{x \rightarrow q} (c \cdot f(x)) = c \cdot \lim_{x \rightarrow q} f(x) \quad , \text{ für } c \in \mathbb{R}$$

$$\lim_{x \rightarrow q} (f(x) + g(x)) = \lim_{x \rightarrow q} f(x) + \lim_{x \rightarrow q} g(x)$$

$$\lim_{x \rightarrow q} (f(x) \cdot g(x)) = \lim_{x \rightarrow q} f(x) \cdot \lim_{x \rightarrow q} g(x)$$

$$\lim_{x \rightarrow q} \left(\frac{f(x)}{g(x)} \right) = \frac{\lim_{x \rightarrow q} f(x)}{\lim_{x \rightarrow q} g(x)}, \text{ falls } \lim_{x \rightarrow q} g(x) \neq 0$$

$$\lim_{x \rightarrow q} (f(x)^{g(x)}) = \left(\lim_{x \rightarrow q} f(x) \right)^{\lim_{x \rightarrow q} g(x)}, \text{ falls } \lim_{x \rightarrow q} f(x) > 0$$

All diese Formeln gelten auch für einseitige Grenzwerte.

Gilt $G = \lim_{x \rightarrow q} g(x)$ (an dieser Stelle ist ein einseitiger Grenzwert nicht ausreichend), so gilt ausserdem:

$$\lim_{x \rightarrow q} f(g(x)) = \lim_{g \rightarrow G} f(g)$$


falls der Grenzwert auf der rechten Seite existiert.

2.4. UNEIGENTLICHE GRENZWERTE IM ENDLICHEN

$$\lim_{x \rightarrow q} f(x) = \infty$$

Für jedes $S \in \mathbb{R}$ gibt es ein $\delta > 0$, so dass $\forall x : 0 < |x - q| < \delta : f(x) > S$

Beispiel 9: $f(x) = \frac{(x-1)^2 - 2x + 10}{(x-2)^2}$



Beobachtungen 6

6.1. Für sehr grosse Argumente sind Funktionswerte sehr gross.

$$\forall x > X : f(x) > S \Rightarrow \lim_{x \rightarrow \infty} f(x) = \infty$$

6.2. Für sehr grosse Argumente sind Funktionswerte stark negativ.

$$\forall x > X : f(x) < S \Rightarrow \lim_{x \rightarrow \infty} f(x) = -\infty$$

6.3. Für stark negative Argumente sind Funktionswerte sehr gross.

$$\forall x < X : f(x) > S \Rightarrow \lim_{x \rightarrow -\infty} f(x) = \infty$$

6.4. Für stark negative Argumente sind Funktionswerte stark negativ.

$$\forall x < X : f(x) < S \Rightarrow \lim_{x \rightarrow -\infty} f(x) = -\infty$$

2.5. SATZ VON BERNOULLI UND L'HOSPITAL

Voraussetzung: Typ $\frac{0}{0}$ (Zähler und Nenner streben gegen 0) oder Typ $\frac{\infty}{\infty}$

Typ $\frac{0}{0}$: $\lim_{x \rightarrow a} f(x) = \lim_{x \rightarrow a} g(x) = 0$

Typ $\frac{\infty}{\infty}$: $\lim_{x \rightarrow a} g(x) = \infty \vee \lim_{x \rightarrow a} g(x) = -\infty$

Ableitung **ohne quotientenregel** (heisst, Zähler und Nenner separat ableiten) gibt dasselbe Resultat für den limes.

$$\lim_{x \rightarrow a} \frac{f(x)}{g(x)} \stackrel{\text{Voraussetzung prüfen}}{=} \lim_{x \rightarrow a} \frac{f'(x)}{g'(x)}$$

$$a \in \mathbb{R} \cup \{\infty, -\infty\}$$

Beweis für $a \in \mathbb{R}$, Typ $\frac{0}{0}$:

Linearisierung von f und g um $x = a$:

$$f(x) \approx f(a) + f'(a)(x - a)$$

$$g(x) \approx g(a) + g'(a)(x - a)$$

$$\frac{f(x)}{g(x)} \approx \frac{f(a) + f'(a)(x - a)}{g(a) + g'(a)(x - a)}$$

$$\lim_{x \rightarrow a} \frac{f(x)}{g(x)} = \lim_{x \rightarrow a} \frac{\cancel{f(a)} + f'(a)(\cancel{x-a})}{\cancel{g(a)} + g'(a)(\cancel{x-a})} \mid f(x) \rightarrow 0 \Rightarrow f(a) = 0$$

Beispiel 10

$$\lim_{x \rightarrow \frac{\pi}{2}} \frac{\overbrace{1 - \sin(x)}^0}{\underbrace{2x - \pi}_0} = \lim_{x \rightarrow \frac{\pi}{2}} \frac{-\cos(x)}{2} = \frac{-\cos\left(\frac{\pi}{2}\right)}{2} = 0$$

Einen Grenzwert vom Typ $\infty \cdot 0$ kann man mit der Umformung

$$f(x) \cdot g(x) = \frac{f(x)}{\frac{1}{g(x)}}$$

in den typ $\frac{\infty}{\infty}$ überführen, oder durch die Umformung

$$f(x) \cdot g(x) = \frac{g(x)}{\frac{1}{f(x)}}$$

auf die Form $\frac{0}{0}$ bringen.

2.6. RECHNEN MIT UNENDLICH GROSSEN «ZAHLEN»

	$z = -\infty$	$-\infty < z < 0$	$z = 0 -$	$z = 0 +$	$0 < z < \infty$	$z = \infty$
$z + \infty = \infty + z$	?	∞	∞	∞	∞	∞
$\infty - z$	∞	∞	∞	∞	∞	?
$z - \infty$	$-\infty$	$-\infty$	$-\infty$	$-\infty$	$-\infty$	?
$z \cdot \infty = \infty \cdot z$	$-\infty$	$-\infty$	B/L*	B/L*	∞	∞
$\frac{\infty}{z}$	B/L	$-\infty$	$-\infty$	∞	∞	B/L
$\frac{z}{\infty}$	B/L	$0 -$	$0 -$	$0 +$	$0 +$	B/L
$\frac{z}{0+}$	$-\infty$	$-\infty$	B/L	B/L	∞	∞
$\frac{z}{0-}$	∞	∞	B/L	B/L	$-\infty$	$-\infty$


* Mit umformen

3. ABLEITUNG

TODO:

polish, notes 28

Differenzenquotient $\frac{f(x) - f(x_0)}{x - x_0}$



Differentialquotient $f'(x_0) = \left. \frac{df}{dx} \right|_{x=x_0} = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$

4. INTERPOLATION

Begriff	Bedeutung
Interpolation	– Füllt Lücken in einer Wertetabelle – Benötigt kein Systemverständnis

TODO:
diagram

Begriff	Bedeutung
Extrapolation	– Dehnt den Definitionsbereich der Funktion über den Messbereich hinaus aus – Benötigt Systemverständnis. Beispiel: Klimamodelle

TODO:
diagram

TODO:

Recherchieren: Logistische regression

Glossar: Kostenfunktion

Fit mit Splines vs Fit mit Parabeln $a + bx + cx^2$

Gegeben: Trainingsdaten = Wertetabelle

Ziel: Vorhersage der y Werte durch x in Form einer Funktion $y = f(x)$

x	0	3	5	
y	80	90	105	← gemessene Werte
$f(x)$	$f(0)$	$f(3)$	$f(5)$	← vorhergesagte Werte
Residuen	$f(0) - 80$	$f(3) - 90$	$f(5) - 105$	← «Güte» der Vorhersage
Quadrat Fehler	$(f(0) - 80)^2$	$(f(3) - 90)^2$	$(f(5) - 105)^2$	← Schafft Vorzeichen weg


Kostenfunktion: $(f(0) - 80)^2 + (f(3) - 90)^2 + (f(5) - 105)^2 = \text{RSS}$

Definition des Suchraums: Linearkombinationen einer vorgegebenen Liste von «Basisfunktionen»

Beispiel 11 : Schiffsahrt

SpeedOnSurface (x_i)	0	3	5	7.5	8	11	14	18	20	22
FuelPerHour (y_i)	80	90	105	140	131	162	197	251	280	310

TODO:




4.1. METHODE DER KLEINSTEN QUADRATE (RSS)

Begriff	Bedeutung
Residuum	$r_i = f(x_i) - y_i$
Quadratischer Fehler	$r_i^2 = (f(x_i) - y_i)^2$
Unabhängige Variable	= Prädiktorvariable Variable x in der Funktion $y = f(x)$
Abhängige Variable	= Responsevariable Variable y in der Funktion $y = f(x)$
Gesamtfehler	= Residual Sum of Squares $RSS = \sum_{i=0}^{N-1} \underbrace{(f(x_i) - y_i)^2}_{\substack{\text{Im Diagramm als rote} \\ \text{Vierecke repräsentiert}}}$

Beispiel 12 : Lineare regression von Gehältern nach Alter

$$RSS(m, b) = \sum_{i=1}^N ((mx_i + b) - y_i)^2 \geq 0, RSS : \mathbb{R}^2 \rightarrow \mathbb{R}$$



4.2. LINEARE REGRESSION

Begriff	Bedeutung
Basisfunktionen	Raum der «besonders einfachen Funktionen» $b_1(x), b_2(x), \dots, b_n(x)$
Modellfunktionen	Linearkombinationen aus Basisfunktionen $\lambda_1 b_1(x), \lambda_2 b_2(x), \dots, \lambda_n b_n(x)$
Regressionskoeffizient	Konstanten λ_k der Modellfunktionen
Mittelwert	$\bar{x} = \frac{1}{N} \sum_{i=0}^{N-1} x_i$
Unkorrigierte Stichprobenvarianz der Variable x	$\sigma^2 = \frac{1}{N} \sum_{i=0}^{N-1} x_i^2 - \bar{x}^2$
Unkorrigierte Stichprobenkovarianz der Variablen x und y	$\text{var}(x, y) = \frac{1}{N} \sum_{i=0}^{N-1} x_i y_i - \bar{x} \cdot \bar{y}$

TODO:

Examples (19.03.26)

Ziel ist es, eine **besonders einfache** Funktion (**Modellfunktion**) zu finden, die eine Wertetabelle am besten interpoliert. «Am besten» $\neq$ exakt!

Zentral ist, dass die Ergebnisfunktionen eine einfache Struktur aufweist.

Genauer: Die Ergebnisfunktion muss eine **Linearkombinationen** (=gewichtete Summe) von **wählbaren Basisfunktionen** $b_1(x) \dots b_n(x)$ d.h. von der Form $f(x) = \sum_{k=1}^n \lambda_k \cdot b_k(x)$ sein.

Die Gewichte λ_k heissen **Regressionskoeffizienten**

Alternativ (Vereinfacht): Gesucht sind die Zahlen $\lambda_1 \dots \lambda_n$, für die $f(x) = \sum_{k=1}^n \lambda_k \cdot b_k(x)$ die Einträge der Wertetabelle am genauesten wiedergibt (= den RSS minimiert)

Gegeben

Wertetabelle						Geeignete Funktionen
x	x_0	x_1	x_2	$\dots$	x_{N-1}	$b_0(x), \dots, b_{m-1}(x)$
y	y_0	y_1	y_2	$\dots$	y_{N-1}	

Aufgabe

Bestimme die besten Regressionsparameter der Modellfunktion

$$f(x) = \sum_{k=0}^{m-1} \underbrace{\lambda_k}_{\text{gesucht}} b_k(x) \quad (1)$$

Methode

Bestimme das globale Minimum des von λ_k abhängigen quadratischen Fehlers

$$\text{RSS} = \sum_{i=0}^{N-1} (f(x_i) - y_i)^2 = \sum_{i=0}^{N-1} \left(\sum_{k=0}^{m-1} \lambda_k b_k(x_i) - y_i \right)^2 \quad (2)$$

Beispiel 13: Ausgleichsgerade

Modellfunktionen	Basisfunktionen	Regressionskoeffizienten
$f(x) = m \cdot x + b$	$b_0(x) = x$ $b_1(x) = 1$	$\text{RSS}(b, m) = \sum_{i=0}^{N-1} (m \cdot x_i + b - y_i)^2$

Ziel: Minimiere RSS

Stationäre Stellen von $\text{RSS} = \text{RSS}(m, b)$

$$\begin{aligned}
 \frac{d\text{RSS}}{db} &= \sum_{i=0}^{N-1} 2(mx_i + b - y_i) = 2 \cdot \left(\left(\sum_{i=0}^{N-1} mx_i \right) + \left(\sum_{i=0}^{N-1} b \right) - \left(\sum_{i=0}^{N-1} y_i \right) \right) \\
 &\stackrel{!}{=} 0 \Leftrightarrow \left(\sum_{i=0}^{N-1} x_i \right) m + N \cdot b = \sum_{i=0}^{N-1} y_i \quad | \div N \\
 &\Leftrightarrow \underbrace{\left(\frac{1}{N} \sum_{i=0}^{N-1} x_i \right)}_{\text{Mittelwert aller } x\text{-Werte}} m + b = \underbrace{\frac{1}{N} \sum_{i=0}^{N-1} y_i}_{\text{Mittelwert aller } y\text{-Werte}} \\
 &\Leftrightarrow \bar{x} \cdot m + b = \bar{y}
 \end{aligned}$$

$$\begin{aligned}
\frac{dRSS}{dm} &= \sum_{i=0}^{N-1} 2(mx_i + b - y_i)x_i = 2\left(\left(\sum_{i=0}^{N-1} mx_i^2\right) + \left(\sum_{i=0}^{N-1} bx_i\right) - \left(\sum_{i=0}^{N-1} y_i x_i\right)\right) \\
&\stackrel{!}{=} 0 \Leftrightarrow \left(\sum_{i=0}^{N-1} x_i^2\right)m + \left(\sum_{i=0}^{N-1} x_i\right)b = \left(\sum_{i=0}^{N-1} y_i x_i\right) \quad | \div N \\
&\Leftrightarrow \underbrace{\left(\frac{1}{N} \sum_{i=0}^{N-1} x_i^2\right)}_{\text{Mittelwert aller } x\text{-Quadrate}} m + \underbrace{\left(\frac{1}{N} \sum_{i=0}^{N-1} x_i\right)b}_{\text{Mittelwert der } x\text{-}y\text{-Produkte}} = \underbrace{\left(\frac{1}{N} \sum_{i=0}^{N-1} y_i x_i\right)}_{\text{Mittelwert der } x\text{-}y\text{-Produkte}} \\
&\Leftrightarrow (\sigma^2 + \bar{x}^2) \cdot m + \bar{x} \cdot b = \text{var}(x, y) + \bar{x} \cdot \bar{y} \\
&\Rightarrow m\sigma^2 = \text{var}(x, y) \\
&\Rightarrow m = \frac{\text{var}(x, y)}{\sigma^2} \\
&\Rightarrow b = \bar{y} - m\bar{x}
\end{aligned}$$

4.2.1. Generalisierung

Das Ziel der linearen Regression ist es, die Regressionskoeffizienten so zu bestimmen, dass die Wertetabelle möglichst genau wiedergegeben wird, d.h. dass

$$\forall i \in [0; N-1] : y_i \approx y_i^{\text{berechnet}} = \sum_{k=0}^{m-1} \lambda_k b_k(x_i) \quad (3)$$

Eine lineare Regression kann durchgeführt werden, sobald $N \geq m$ Datensätze (x_i, y_i) vorliegen.

Eine geschlossene Formel für die Regressionskoeffizienten zu finden verlangt Matrizenrechnung. Die Daten und Basisfunktionen können wie folgt in Matrizenform dargestellt werden:

Wertetabelle	Designmatrix	Ergebnis- vektor																														
<table border="0" style="width: 100%; border-collapse: collapse;"> <tr> <th style="text-align: left; padding: 5px;">x</th> <th style="text-align: left; padding: 5px;">$b_0(x)$</th> <th style="text-align: left; padding: 5px;">$b_1(x)$</th> <th style="text-align: left; padding: 5px;">$\dots$</th> <th style="text-align: left; padding: 5px;">$b_{m-1}(x)$</th> <th style="text-align: left; padding: 5px;">y</th> </tr> <tr> <td style="padding: 5px;">x_0</td> <td style="padding: 5px;">$b_0(x_0)$</td> <td style="padding: 5px;">$b_1(x_0)$</td> <td style="padding: 5px;">$\dots$</td> <td style="padding: 5px;">$b_{m-1}(x_0)$</td> <td style="padding: 5px;">y_0</td> </tr> <tr> <td style="padding: 5px;">x_1</td> <td style="padding: 5px;">$b_0(x_1)$</td> <td style="padding: 5px;">$b_1(x_1)$</td> <td style="padding: 5px;">$\dots$</td> <td style="padding: 5px;">$b_{m-1}(x_1)$</td> <td style="padding: 5px;">y_1</td> </tr> <tr> <td style="padding: 5px;">$\vdots$</td> <td style="padding: 5px;">$\vdots$</td> <td style="padding: 5px;">$\vdots$</td> <td style="padding: 5px;">$\ddots$</td> <td style="padding: 5px;">$\vdots$</td> <td style="padding: 5px;">$\vdots$</td> </tr> <tr> <td style="padding: 5px;">x_{N-1}</td> <td style="padding: 5px;">$b_0(x_{N-1})$</td> <td style="padding: 5px;">$b_1(x_{N-1})$</td> <td style="padding: 5px;">$\dots$</td> <td style="padding: 5px;">$b_{m-1}(x_{N-1})$</td> <td style="padding: 5px;">y_{N-1}</td> </tr> </table>	x	$b_0(x)$	$b_1(x)$	$\dots$	$b_{m-1}(x)$	y	x_0	$b_0(x_0)$	$b_1(x_0)$	$\dots$	$b_{m-1}(x_0)$	y_0	x_1	$b_0(x_1)$	$b_1(x_1)$	$\dots$	$b_{m-1}(x_1)$	y_1	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	x_{N-1}	$b_0(x_{N-1})$	$b_1(x_{N-1})$	$\dots$	$b_{m-1}(x_{N-1})$	y_{N-1}	$B = \begin{pmatrix} b_0(x_0) & b_1(x_0) & \dots & b_{m-1}(x_0) \\ b_0(x_1) & b_1(x_1) & \dots & b_{m-1}(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ b_0(x_{N-1}) & b_1(x_{N-1}) & \dots & b_{m-1}(x_{N-1}) \end{pmatrix}$	$\vec{y} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{pmatrix}$
x	$b_0(x)$	$b_1(x)$	$\dots$	$b_{m-1}(x)$	y																											
x_0	$b_0(x_0)$	$b_1(x_0)$	$\dots$	$b_{m-1}(x_0)$	y_0																											
x_1	$b_0(x_1)$	$b_1(x_1)$	$\dots$	$b_{m-1}(x_1)$	y_1																											
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$																											
x_{N-1}	$b_0(x_{N-1})$	$b_1(x_{N-1})$	$\dots$	$b_{m-1}(x_{N-1})$	y_{N-1}																											
(N × m) - Matrix																																

Zusätzlich definiert man den **Koeffizientenvektor**

$$\vec{\lambda} = \begin{pmatrix} \lambda_0 \\ \lambda_1 \\ \vdots \\ \lambda_{m-1} \end{pmatrix}$$

wodurch die [Gleichung 3](#) in eine Matrixgleichung umgeschrieben werden kann:

$$\underbrace{\vec{y}}_{\in \mathbb{R}^N} \approx \underbrace{B}_{\in \mathbb{R}^{N \times m}} \cdot \underbrace{\vec{\lambda}}_{\in \mathbb{R}^m}$$

Auch der RSS ([Gleichung 2](#)) lässt sich nun in Matrixform darstellen:

$$\text{RSS} = (\vec{y} - B \cdot \vec{\lambda})^2 = (\vec{y} - B \cdot \vec{\lambda}) \cdot (\vec{y} - B \cdot \vec{\lambda})$$

Ferner: Die Modellfunktion der [Gleichung 1](#) minimiert den quadratischen Fehler RSS genau dann, wenn der Koeffizientenvektor $\vec{\lambda}$ eine Lösung der Gleichung

$$B^T \vec{y} = B^T B \vec{\lambda}$$

$$\stackrel{\text{Rang } B=m}{\Leftrightarrow} (B^T B)^{-1} B^T \vec{y} = \vec{\lambda}$$

ist.

TODO:
Beweis

Beispiel 14

TODO:

4.3. OVERFITTING

Wenn ein Modell nur über **wenige Konfigurationsparameter** verfügt, ist seine «Lernfähigkeit» eingeschränkt. Eine lineare Regression, die nur die Basisfunktionen 1 und x enthält, führt zwangsweise auf lineare Modellfunktion $f(x) = mx + b$ und kann kompliziertere Abhängigkeiten nicht wiedergeben. Man spricht in diesem Fall von einer «Unteranpassung» oder einem **Underfitting**.

Allerdings kann es auch vorkommen, dass ein Modell **zu viele Konfigurationsparameter** besitzt, um gute Vorhersagen zu leisten. Da die Notwendigkeit, zu generalisieren, verschwindet, wenn es weniger Messwerte als Regressionsparameter gibt, kann die Modellfunktion im Fall $m \geq N$ die Messdaten (inkl. eventuell vorhandener Fehler) einfach «auswendig lernen». Dieser Effekt heisst «Überanpassung» (**Overfitting**).

TODO:
diagrams

4.4. WAHL DER BASISFUNKTION

Neben den bis jetzt besprochenen linearen Basisfunktionen gibt es Polynomiale Basisfunktionen vom Typ

$$x^k$$

Gauss'sche Basisfunktionen vom Typ

$$e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$

Sigmoid-Basisfunktionen vom Typ

$$\frac{1}{1 + e^{-\frac{x-\mu}{s}}}$$

und trigonometrischen Basisfunktionen vom Typ

$$\sin(k\omega x) \text{ oder } \cos(k\omega x), k \in \mathbb{Z}$$

TODO:
diagrams

Dabei fällt auf, dass sich die Regressionskurven in dem Bereich, in dem Messdaten zur Verfügung stehen kaum voneinander unterscheiden, während ausserhalb dieses Bereichs grosse Unterschiede zwischen den verschiedenen Regressionskurven sichtbar werden.

<i>Funktion</i>	<i>Eignung</i>	<i>Beispiel</i>
Fourierbasis (trigonometrische Basisfunktion)	Periodische Zyklen	Wetterdaten
Sigmoid-Basis	Daten, die für sehr grosse und sehr kleine Argumente gegen zwei unterschiedliche endliche Grenzwerte streben	Welcher Bevölkerungsanteil ein gewisses Jahreseinkommen unterschreitet
Gauss'sche Basis	Eine abhängige Variable, die für grosse und kleine Argumente annähernd Null ist	Wahrscheinlichkeit, dass ein Mensch eine bestimmte Körpergrösse besitzt
Polynomiale Basis	Wenn die Daten nur innerhalb des Messbereichs interpoliert werden sollen oder wenn man von vornherein weiss, dass der Zusammenhang zwischen zwei Messgrössen linear oder quadratisch ist	Machinelles Lernen