

Automaten und Sprachen | AutoSpr

Zusammenfassung

INHALTSVERZEICHNIS

1. Prädikate	3
1.1. Normalformen	3
1.2. Negation	3
2. Mengen	3
2.1. Konstruktion	3
2.2. Operationen	3
2.3. Tupel	3
3. Beweise	3
4. Sprachen	4
4.1. Wortlänge	4
4.2. Deterministische Endliche Automaten (DEA)	5
4.3. Wörter einer regulären Sprache	5
4.3.1. Übergangsfunktionen für Wörter	5
4.3.2. Wort akzeptieren	5
4.3.3. Akzeptierte Sprache, reguläre Sprache	5
4.4. Myhill-Nerode Automat	6
4.5. Minimalautomat	6
4.6. Pumping Lemma	7
4.6.1. Beweis	7
4.7. Nichtdeterministische endliche Automaten (NEA)	8
4.7.1. Umgang mit mehrdeutigen Übergängen	8
4.7.2. Thompson-NEA	9
4.7.3. NEA_ϵ	9
4.8. Mengenoperationen	9
4.9. Reguläre Operationen	11
4.9.1. Alternative	11
4.9.2. Verkettung	12
4.9.3. *-Operation	12
4.10. Reguläre Ausdrücke	12
4.10.1. Verallgemeinerter NEA (VNEA)	12
4.10.2. Teststrategie	14
4.11. Kontextfreie Sprachen	14
4.11.1. Kontextfreie Grammatik und Sprache	14
4.11.2. Mehrere Grammatiken	15
4.11.3. Reguläre Operationen	15
4.11.4. Kontextfrei	15
4.11.5. Ableitung	15
4.11.6. Chomsky-Normalform (CNF)	16
4.11.7. Cocke-Younger-Kasami Algorithmus (CYK)	17
5. Stack	17
5.1. Stackautomat / Pushdown Automaton (PDA)	18

5.1.1. Ableitung aus CNF	18
5.1.2. PDA $\rightarrow$ CFG	19
6. Parsing	21
6.1. Backus-Naur-Form (BNF)	21
6.2. Extended Backus-Naur-Form (EBNF)	22
6.3. Rechtsrekursion	22
7. Unendlich	22

1. PRÄDIKATE

Prädikate sind Aussagen über mathematische Objekte, die wahr oder falsch sein können. «Funktionen» mit booleschen Rückgabewerten: $P, Q(n), R(x, y, z)$. Siehe [DMI](#).

1.1. NORMALFORMEN

Normalformen (allgemein, *kanonische Formen*) helfen, das Vergleichsproblem zu lösen (ob zwei Aussagen dieselben sind).

$$P_1 \wedge \dots \wedge P_n = \forall i \in \{1, \dots, n\} (P_i) = \bigwedge_{i=1}^n P_i$$

$$P_1 \vee \dots \vee P_n = \exists i \in \{1, \dots, n\} (P_i) = \bigvee_{i=1}^n P_i$$

1.2. NEGATION

Nicht für alle = Es gibt einen Fall, für den nicht

$$\neg \forall i \in \{1, \dots, n\} (P_i) \Leftrightarrow \neg (P_1 \wedge \dots \wedge P_n) \Leftrightarrow \neg P_1 \vee \dots \vee \neg P_n \Leftrightarrow \exists i \in \{1, \dots, n\} (\neg P_i)$$

2. MENGEN

2.1. KONSTRUKTION

Grundmenge G , Prädikat $P(x)$. Konstruierte Menge $A = \{x \in G \mid P(x)\}$

2.2. OPERATIONEN

Begriff	Bedeutung
Vereinigung	$A \cup B = \{x \mid x \in A \vee x \in B\}$
Schnittmenge	$A \cap B = \{x \mid x \in A \wedge x \in B\}$
Komplement	$\overline{A} = \{x \mid x \notin A\}$
Differenz	$A \setminus B = \{x \in A \mid x \notin B\}$

2.3. TUPEL

$$A \times B = \{(a, b) \mid a \in A \wedge b \in B\}$$

n -Tupel:

$$\bigtimes_{i=1}^n A_i = \{(a_1, a_2, \dots, a_n) \mid a_i \in A_i\}$$

3. BEWEISE

Eine Folge von logischen Schlüssen, die zeigen, dass die Aussage aus den gegebenen Voraussetzungen folgt.

Beweistechnik	Anwendungsfall
Konstruktiver Beweis	Liefert explizite «Lösung» / Algorithmus
Widerspruchsbeweis	Geeignet für Unmöglichkeitsaussagen. Z.B. $\sqrt{2} \notin \mathbb{Q}$
Vollständige Induktion	Für Aussagen, die für alle $n \in \mathbb{N}$ gelten.

4. SPRACHEN

Begriff	Bedeutung
Alphabet	Eine nichtleere endliche Menge Σ heisst Alphabet . Die Elemente von Σ heissen Zeichen .
Wort	Eine Zeichenkette der Länge n ist ein n -Tupel in $\Sigma^n = \Sigma \times \dots \times \Sigma$. Ein Element von Σ^n heisst Wort der Länge n . Wörter haben immer endliche Länge.
Leeres Wort	Die Zeichenkette $\varepsilon \in \Sigma^0 = \{\varepsilon\}$ der Länge 0 heisst das leere Wort .
Menge aller Wörter	Leeres Wort ist immer drin $\Sigma^* = \{\varepsilon\} \cup \Sigma \cup \Sigma^2 \cup \Sigma^3 \cup \dots = \bigcup_{k=0}^{\infty} \Sigma^k$
Abgekürzte Schreibweisen von Wörtern	$(A, u, t, o, S, p, r) = AutoSpr$ $a^3 b^5 = aaabbbbbb$ $b^5 a^3 = bbbbaaaa$
Sprache	Teilmenge $L \subset \Sigma^*$

4.1. WORTLÄNGE

Begriff	Bedeutung
Länge des Wortes	$w \in \Sigma^n \Rightarrow w = n$, n ist Länge des Wortes w
Anzahl Zeichen	Sei $w \in \Sigma^n$, $a \in \Sigma$. Dann ist $ w _a$ die Anzahl Zeichen a im Wort w

Beispiel 1 : Wortlänge

$$\begin{array}{lll}
 |\varepsilon| = 0 & |01010|_1 = 2 & |a^3 b^5| = 8 \\
 |01010|_0 = 3 & |01010|_3 = 0 & |(1291)^7| = 7|1291| = 7 \cdot 4 = 28
 \end{array}$$

Beispiel 2 : Sprache

$$\begin{array}{l}
 L = \Sigma^* \subset \Sigma^* \\
 L = \emptyset \subset \Sigma^*, \text{ die leere Sprache} \\
 \Sigma = \{0, 1\}, \text{ Sprache aller Binärstrings: } L = \Sigma^*
 \end{array}$$

$$\Sigma = \text{Unicode}, J = \{w \in \Sigma^* \mid w \text{ wird vom Java-Compiler akzeptiert}\}$$

$$M \text{ eine "Maschine", } L(M) = \{w \in \Sigma^* \mid w \text{ wird von } M \text{ akzeptiert}\}$$

Beobachtungen 1

- 1.1. $|w^n| = n \cdot |w|$
- 1.2. Zu jeder Maschine M gibt es eine Sprache $L(M)$

4.2. DETERMINISTISCHE ENDLICHE AUTOMATEN (DEA)

Definition


$$A = (\mathcal{Q}, \Sigma, \delta, q_0, F)$$

- Zustände: $\mathcal{Q} = \{q_0, q_1, \dots, q_n\}$
- Alphabet: Σ
- Übergangsfunktion: $\delta : \mathcal{Q} \times \Sigma \rightarrow \mathcal{Q}$
- Startzustand: $q_0 \in \mathcal{Q}$
- Akzeptierzustände: $F \subset \mathcal{Q}$

Tabellenform

		0	1	Σ
$\mathcal{Q}$	q_0	q_2	q_1	δ
	q_1	q_0	q_1	
	q_2	q_1	q_2	

Zustandsdiagramm von A



Wichtig:

- Ein Pfeil für jedes Zeichen in jedem Zustand (deterministischer endlicher Automat / DEA)

4.3. WÖRTER EINER REGULÄREN SPRACHE

4.3.1. Übergangsfunktionen für Wörter

$$\delta : \mathcal{Q} \times \Sigma^* \rightarrow \mathcal{Q} : (q, w = a_1, \dots, a_n) \mapsto \delta(\dots \delta(\delta(q, a_1), a_2), \dots, a_n)$$

Übergänge ausgehend von q für Zeichen $a_1, \dots, a_n$ nacheinander anwenden.

4.3.2. Wort akzeptieren

Der DEA $A = (\Sigma, \mathcal{Q}, q_0, \delta, F)$ **akzeptiert** das Wort $w \in \Sigma^*$, wenn er A von Startzustand in einen Akzeptierzustand $\delta(q_0, w) \in F$ überführt.


4.3.3. Akzeptierte Sprache, reguläre Sprache

Gegeben ein DEA $A = (\Sigma, \mathcal{Q}, q_0, \delta, F)$. Die von A **akzeptierte Sprache** ist

$$L(A) = \{w \in \Sigma^* \mid A \text{ akzeptiert } w\} = \{w \in \Sigma^* \mid \delta(q_0, w) \in F\}$$

Die Sprache $L \subset \Sigma^*$ heisst **regulär**, wenn es einen DEA A gibt mit $L(A) = L$

Beispiel 3: DEA, der die Sprache $L = \{w \in \Sigma^* \mid w \text{ ist eine ungerade Zahl im Dreiersystem}\}$ akzeptiert



	0	1	2
g	g	u	g
u	u	g	u

4.4. MYHILL-NERODE AUTOMAT


Für ein Wort $w \in \Sigma^*$ setze $L(w) = \{w' \in \Sigma^* \mid ww' \in L\}$. Insbesondere $L(\varepsilon) = L$

Gegeben: reguläre Sprache L über Σ . Rekonstruiere A mit:

- $Q = \{L(w) \mid w \in \Sigma^*\}$
- $q_0 = L(\varepsilon) = L$
- $F = \{L(w) \in Q \mid \varepsilon \in L(w)\}$
- $\delta(L(w), a) = L(wa)$

Gleicher Zustand $\Leftrightarrow$ gleiches $L(w)$

Beispiel 4: $\Sigma = \{0, 1\}$, $L = \{w \in \Sigma^* \mid |w|_0 \text{ gerade}\}$



w	$L(w)$	Q
ε	$L(\varepsilon) = L$	q_0
0	$L(0) = \{w \in \Sigma^* \mid w _0 \text{ ungerade}\}$	q_1
1	$L(1) = \{w \in \Sigma^* \mid w _0 \text{ gerade}\}$	q_0
$\vdots$	$\vdots$	$\vdots$


4.5. MINIMALAUTOMAT

Ziel: Nicht unterscheidbare Zustände zusammenlegen

Vorgehen:


- 1) Akzeptierzustand $\neq$ Nichtakzeptierzustand
- 2) Iteration: alle unterscheidbaren Paare suchen
- 3) Verbleibende Paare sind ununterscheidbar $\rightarrow$ zusammenlegen

Beispiel 5



	q_0	q_1	q_2	q_3
q_0	$\equiv$	$\times$	$\times$	$\times$
q_1	$\times$	$\equiv$	$\equiv$	$\times$
q_2	$\times$	$\equiv$	$\equiv$	$\times$
q_3	$\times$	$\times$	$\times$	$\equiv$

Algorithmus




- 1) $q \in F, q' \notin F$
 - 2) Unterscheidbar nach Übergang
 - 3) Iteration bis keine Änderung mehr
- $\Rightarrow q_1$ und q_2 sind nicht unterscheidbar

4.6. PUMPING LEMMA

Ist L eine reguläre Sprache, dann gibt es $N \in \mathbb{N}$, die pumping length so, dass jedes Wort $w \in L$ mit $|w| \geq N$ in drei Teile $w = xyz$ zerlegt werden kann mit:

- 1) $|xy| \leq N$
- 2) $|y| > 0$
- 3) $xy^kz \in L \forall k \in \mathbb{N}$

Oder: genügend lange Wörter ($|w| \geq N$) einer regulären Sprache ($w \in L$) können alle in einem Anfangsstück der Länge N ($|xy| \leq N$) aufgepumpt werden ($xy^kz \in L$).



Was zeichnet reguläre Sprachen aus?

- Reguläre Ausdrücke
- Lange Wörter: * kommt im regulären Ausdruck vor
- Blöcke mit * können beliebig oft wiederholt werden
- $\Rightarrow$ Wörter können «aufgepumpt» werden

4.6.1. Beweis

Behauptung: Die Sprache $L \subset \Sigma^*$ ist nicht regulär.

Beweis (Widerspruch):


- 1) Annahme: L ist regulär
- 2) Gemäss Pumping Lemma gibt es die Pumping Length N
 - Es darf keine Annahme über die konkrete Grösse von N gemacht werden!
- 3) Wähle ein Wort $w \in L$ mit $|w| \geq N$
 - Die Definition **muss** N verwenden!
- 4) Aufteilung des Wortes gemäss Pumping Lemma
 - $w = xyz, |xy| \leq N, |y| > 0$
- 5) Auswirkung des Pumpens
 - $xy^kz \notin L$ für mindestens ein $k \in \mathbb{N}$ (mit Begründung!)
- 6) Widerspruch und Schlussfolgerung, dass die Annahme nicht zutreffen kann

Beispiel 6: $L = \{0^n 1^n \mid n \geq 0\}$ ist nicht regulär

- 1) Annahme: L ist regulär
- 2) $\exists N \in \mathbb{N}$, Pumping Length
- 3) $w = 0^N 1^N$
- 4) Unterteilung $w = xyz$

TODO:

reduce confusion



5) Pumpen: nur die Anzahl der 1 wird erhöht, Anzahl 1 bleibt

6) $xy^kz \notin L$ für $k \neq 1$, im Widerspruch zum Pumping Lemma

4.7. NICHTDETERMINISTISCHE ENDLICHE AUTOMATEN (NEA)

Definition

$$A = (Q, \Sigma, \delta, q_0, F)$$

- Endliche Menge von Zuständen: Q
- Alphabet: Σ
- Übergangsfunktion: $\delta : Q \times \Sigma \rightarrow P(Q)$
- Startzustand: $q_0 \in Q$
- Akzeptierzustände: $F \subset Q$

Akzeptieren


Ein NEA A **akzeptiert** das Wort $w \in \Sigma^*$, wenn es eine **Wahl** von Übergängen gibt, derart, dass das Wort w den Automaten in einen Akzeptierzustand überführt.

Faustregeln


- Nur genau diejenigen Pfeile einzeichnen, die man zum Akzeptieren braucht.
- Erlaube Alternativen

Beispiel 7: $L = \{w \in \Sigma^* \mid w \text{ endet mit zwei } 0\}$

DEA-Lösung



NEA-Lösung




4.7.1. Umgang mit mehrdeutigen Übergängen

a-Übergang von q_1 aus nicht eindeutig


Welchen Übergang soll man nehmen?

- Beide Möglichkeiten probieren und akzeptieren, falls eine der Möglichkeiten auf einen Akzeptierzustand führt.
- Zufallsgenerator (probabilistischer endlicher Automat, PEA)



4.7.2. Thompson-NEA

- Zustand = **Menge** der möglichen Zustände
- Akzeptieren = Ob NEA im Zustand sein **könnte**



4.7.2.1. Transformation NEA → DEA

Gegeben $\delta : Q \times \Sigma \rightarrow P(Q)$ eines NEA. Übergangsfunktion für Mengen $M \subset Q$

$$\delta' : P(Q) \times \Sigma \rightarrow P(Q) : (M, a) \mapsto \delta'(M, a) = \bigcup_{q \in M} \delta(q, a)$$

Satz

Ein NEA A kann in einen DEA A' umgewandelt werden mit

- $Q' = P(Q)$
- $\Sigma' = \Sigma$
- δ' wie oben definiert
- $q'_0 = \{q_0\}$
- $F' = \{M \in P(Q) \mid F \cap M \neq \emptyset\}$

Implementation

Thompson-NEA:

- Zustand $M \subset Q$ realisiert durch Markierung der Zustände in M
- δ' realisiert durch Verschieben von Markierungen
- Akzeptieren: mindestens ein Akzeptierzustand markiert


4.7.3. NEA_ϵ

Begriff	Bedeutung
ϵ -Übergang	Kann ohne Verarbeitung eines Zeichens genommen werden. $\delta : Q \times (\Sigma \cup \{\epsilon\}) \rightarrow P(Q)$
NEA_ϵ	NEA mit ϵ -Übergängen

Einen NEA_ϵ kann man immer in einen NEA umwandeln. Beweis:

- 1) $E(q)$ = Menge der von q aus mit ϵ -Übergängen erreichbaren Zustände
- 2) $E(M) = \bigcup_{q \in M} E(q)$
- 3) δ ersetzen durch $\delta : Q \times (\Sigma \cup \{\epsilon\}) \rightarrow P(Q) : (q, a) \mapsto E(\delta(q, a))$

$$L = \{0^k 1^l \mid k, l \geq 0\}$$






4.8. MENGENOPERATIONEN





Lassen reguläre Sprachen regulär sein.

Produktautomat: $L_i = L(A_i)$

$$L = \{w \in \Sigma^* \mid |w|_1 \text{ ungerade}\} \cap \{w \in \Sigma^* \mid w \text{ ist eine durch drei teilbare Binärzahl}\}$$

A_2



Schnittmenge $L(A_1) \cap L(A_2)$ Vereinigungsmenge $L(A_1) \cup L(A_2)$ Differenzmenge $L(A_1) \setminus L(A_2)$ Symmetrische Differenz $L(A_1) \triangle L(A_2)$ 

Operationen verändern nur Endzustände:


Begriff	Bedeutung
Schnittmenge $L_1 \cap L_2$	$F = F_1 \times F_2$
Vereinigung $L_1 \cup L_2$	$F = F_1 \times Q_2 \cup Q_1 \times F_2$
Differenz $L_1 \setminus L_2$	$F = F_1 \times (Q_2 \setminus F_2)$

4.9. REGULÄRE OPERATIONEN

WICHTIG: ϵ -Übergänge immer hinzufügen


4.9.1. Alternative

$$\begin{aligned}
 L &= L_1 \cup L_2 \\
 &= L(A_1) \cup L(A_2) \\
 &= L(A_1) \mid L(A_2)
 \end{aligned}$$




4.9.2. Verkettung

$$\begin{aligned}
 L &= L_1 L_2 \\
 &= L(A_1) L(A_2) \\
 &= \{w_1 w_2 \mid w_i \in L_i\}
 \end{aligned}$$



4.9.3. *-Operation

$$\begin{aligned}
 L^* &= \{\varepsilon\} \cup L \cup L^2 \cup \dots \\
 &= \bigcup_{k=0}^{\infty} L^k
 \end{aligned}$$



⇒ die Klasse der regulären Sprachen ist abgeschlossen unter regulären Operationen

4.10. REGULÄRE AUSDRÜCKE

Formeln, die Zeichenketten beschreiben.

- 1) Buchstaben stehen für sich selbst, mit Ausnahme der Metazeichen $()[]*?|.\backslash$ (escape character)
- 2) Verkettung: Zeichen und Formeln hintereinanderschreiben
- 3) $.$ = ein beliebiges Zeichen, Σ
- 4) $|$: Alternative, $a|A = a$ oder A
- 5) $*$: Wiederholung, beliebige viele
- 6) $()$: Gruppierung
- 7) $[]$ Zeichenklassen: $[abc] = a|b|c$, $[\wedge abc] = \text{nicht } [abc]$

Erweiterungen / Dialekte

- 1) $\{n, m\}$: zwischen n und m Wiederholungen
- 2) $+$: mindestens eines, $\{1, \infty\}$
- 3) $?$: optional, $\{0, 1\}$
- 4) Symbole für Zeichenklassen: $\backslash d$ Ziffern, $\backslash s$ whitespace, $[: space :]$, $[: lower :]$

4.10.1. Verallgemeinerter NEA (VNEA)


Begriff	Bedeutung
Regulärer Ausdruck	Zeichenkette r zur Beschreibung einer regulären Sprache $L = L(r)$
Reguläre Operationen	$L(r_1) \cup L(r_2) = L(r_1 r_2)$ $L(r_1) L(r_2) = L(r_1 r_2)$ $L(r_1)^* = L(r_1^*)$
Verallgemeinerter NEA	NEA_ε , dessen Übergänge mit regulären Ausdrücken beschriftet sind

Begriff	Bedeutung	
Primitive reguläre Ausdrücke	Reguläre Ausdrücke für Wörter mit Länge ≤ 1	
	$L = L(r)$	r NEA
$\emptyset$	$\emptyset$	Start $\rightarrow$
$\{\varepsilon\}$	$\{\varepsilon\}$	Start $\rightarrow$
$\{a\}$	a	Start $\rightarrow$
$\{o, s, t\}$	$[ost]$	Start $\rightarrow$
$\{a, b, \dots, s\}$	$[a-s]$	Start $\rightarrow$
Σ	$.$	Start $\rightarrow$


$\Rightarrow$ zu jedem regulären Ausdruck gibt es einen DEA

4.10.1.1. VNEA A umwandeln in Regex r

Keine Übergänge nach q_0 und nur ein Akzeptierzustand




Reduktion



Regulärer Ausdruck

Nach Entfernen aller Zwischenzustände $q_{rip} \in Q$ bleibt ein regulärer Ausdruck r von A



$\Rightarrow$ jede reguläre Sprache lässt sich mit einem regulären Ausdruck beschreiben $\{L(A) \mid A \text{ ein DEA}\} = \{L(r) \mid r \text{ ein regulärer Ausdruck}\}$


Interessantes projekt (DEA Lexer DSL): [Ragel](#)

4.10.2. Teststrategie

Messung	Folgerung
Für $n = 1, 2, 3, \dots$ – Regulären Ausdruck erzeugen $r = \underbrace{a^? a^? a^? a^? \dots a^? a^? a^? a^?}_{n \cdot a^?} \underbrace{aaaa \dots a}_{n \cdot a}$ – Laufzeit für Akzeptieren von a^n durch r messen	– Laufzeit $O(2^n)$: NEA-Implementation – Laufzeit $O(n)$: DEA-Implementation

4.11. KONTEXTFREIE SPRACHEN

Begriff	Bedeutung
CFL	Context Free Language
CFG	Context Free Grammar
PDA	Pushdown Automata



4.11.1. Kontextfreie Grammatik und Sprache

Kontextfreie Grammatik: $G = (V, \Sigma, R, S)$

- V : Variablen
- Σ : Terminalsymbole (Alphabet)
- R : Regeln der Form $A \rightarrow x_1 x_2 \dots x_n$ mit $A \in V, x_i \in V \cup \Sigma$
- S : Startvariable

Ableitung und erzeugte Sprache


- Regel $A \rightarrow w$ erzeugt aus uAv das Wort uwv : $uAv \Rightarrow^* uwv$
- v aus u ableiten: $u \Rightarrow u_1 \Rightarrow u_2 \Rightarrow \dots \Rightarrow u_n \Rightarrow v$ oder $u \Rightarrow^* v$
- $L(G) = \{w \in \Sigma^* \mid S \Rightarrow^* w\}$ von G erzeugte kontextfreie Sprache

Parse Tree

$$L = \{w \in \{0, 1\}^* \mid |w|_0 = |w|_1\}$$

mit der Grammatik

$$S \rightarrow 0S1 \mid 1S0 \mid SS \mid \epsilon$$



Beispiel 8: $L = \{0^n 1^n \mid n \geq 0\}$

Grammatik $L = \{0^n 1^n \mid n \geq 0\}$

Wörter, die erzeugt werden müssen

1) Variablen: $V = \{S\}$

2) Terminalsymbole: $\Sigma = \{0, 1\}$

3) Regeln: $R = \{S \rightarrow \epsilon \mid 0S1\}$

4) Startvariable: S

ϵ

$01 = 0\epsilon 1$

$0011 = 0011$

4.11.2. Mehrere Grammatiken

TODO:

Eindeutigkeit

4.11.3. Reguläre Operationen

Grammatik für reguläre Operationen

L_1 und L_2 kontextfreie Sprachen mit Grammatiken $G_i = (V_i, \Sigma, R_i, S_i)$.

Grammatik für reguläre Operationen:

- Neue Startvariable S_0
- $V = V_1 \cup V_2 \cup \{S_0\}$
- geeignet erweiterte Regeln $R \Rightarrow G = (V, \Sigma, R, S_0)$

Satz

Die Klasse der kontextfreien Sprachen ist abgeschlossen unter regulären Operationen.

Reguläre Sprachen sind kontextfrei.

Alternative

Regeln für $L_1 \cup L_2$:

$$R = R_1 \cup R_2 \cup \{S_0 \rightarrow S_1, S_0 \rightarrow S_2\}$$

Verkettung

Regeln für $L_1 L_2$:

$$R = R_1 \cup R_2 \cup \{S_0 \rightarrow S_1 S_2\}$$

*-Operation

Regeln für L_1^* :

$$R = R_1 \cup \{S_0 \rightarrow S_0 S_1, S_0 \rightarrow \epsilon\}$$

4.11.4. Kontextfrei

Regeln ohne Kontext

$$S \rightarrow A \mid C$$

$$A \rightarrow a$$

$$A \rightarrow aAb$$

$$C \rightarrow bA$$

Regeln mit Kontext

$$S \rightarrow C \mid aC \mid bC$$

$$aC \rightarrow A$$

$$bC \rightarrow B$$

Es spielt keine Rolle, in welchem Kontext das Zeichen A vorkommt, die Regel kann immer angewendet werden

$$S \rightarrow aAb \rightarrow aab$$

Je nach **Kontext** kann eine Regel nicht unbedingt angewendet werden

$$S \rightarrow aC \rightarrow A$$

$$S \rightarrow bC \rightarrow B$$

$$S \rightarrow C \rightarrow ?$$

Python ist nicht kontextfrei lmao

4.11.5. Ableitung

Probleme

1) Unit-rules

$$\left. \begin{array}{l} A \rightarrow B \\ B \rightarrow A \\ A \rightarrow a \end{array} \right\} \Rightarrow A \rightarrow B \rightarrow \underbrace{A \rightarrow B \rightarrow \dots \rightarrow A}_{\text{beliebig lange}} \rightarrow a$$

Lösung

- 1) Keine Unit-rules $A \rightarrow B$
- 2) Keine Regeln $A \rightarrow \epsilon$ ausser wenn nötig $S \rightarrow \epsilon$
- 3) Keine Regeln mit mehr als 2 Variablen auf der rechten Seite

2) «Aufblasen» und «Luft rauslassen»

Genauer: rechte Seite enthält genau zwei Variablen oder genau ein Terminalsymbol

$$\left. \begin{array}{l} A \rightarrow ABCD \mid a \\ B \rightarrow \varepsilon \\ C \rightarrow \varepsilon \\ D \rightarrow \varepsilon \end{array} \right\} \Rightarrow A \rightarrow ABCD \rightarrow ABC \rightarrow AB \rightarrow A \rightarrow a$$

4.11.6. Chomsky-Normalform (CNF)

Eine CFG ist in **Chomsky-Normalform**, wenn S auf der rechten Seite nicht vorkommt und jede Regel von der Form $A \rightarrow BC$ oder $A \rightarrow a$ ist, zusätzlich ist die Regel $S \rightarrow \varepsilon$ erlaubt.

4.11.6.1. Umwandlung

- 1) Neue Startvariable $S_0 \rightarrow S$ (wenn nötig)
- 2) ε -Regeln: $\left. \begin{array}{l} A \rightarrow \varepsilon \\ B \rightarrow AC \end{array} \right\} \Rightarrow A \text{ kann weggelassen werden} \Rightarrow \left\{ \begin{array}{l} B \rightarrow AC \\ \quad \rightarrow AC \end{array} \right.$
- 3) Unit-Rules: $\left. \begin{array}{l} A \rightarrow B \\ B \rightarrow CD \end{array} \right\} \Rightarrow \text{aus } A \text{ kann man wie aus } B \text{ auch } CD \text{ machen} \Rightarrow \left\{ \begin{array}{l} A \rightarrow CD \\ B \rightarrow CD \end{array} \right.$
- 4) Verkettungen: $A \rightarrow u_1 u_2 \dots u_n$ ersetzen durch $A \rightarrow u_1 A_1, A_1 \rightarrow u_2 A_2, \dots, A_{n-2} \rightarrow u_{n-1} u_n$ und falls u_i ein Terminalsymbol ist: $A_{i-1} \rightarrow U_i A_i, U_i \rightarrow u_i$.

4.11.6.2. Folgerungen

- 1) Ableitung eines Wortes $w \in L(G)$ ist immer in $2|w| - 1$ Regelanwendungen möglich. Beweis:
 - $|w| - 1$ Regeln der Form $A \rightarrow BC$ um aus S ein Wort aus $|w|$ Variablen zu erzeugen
 - $|w|$ Regeln der Form $A \rightarrow a$ um das Wort w zu erzeugen
 - $\Rightarrow$ insgesamt $2|w| - 1$ Regelanwendungen
- 2) Deterministischer Parse-Algorithmus mit Laufzeit $O(|w|^3)$

$$S \rightarrow ASA \mid aB$$

Beispiel 9: $A \rightarrow B \mid S$

$$B \rightarrow b \mid \varepsilon$$

1) Startvariable

$$\begin{array}{l} S_0 \rightarrow S \\ S \rightarrow ASA \mid aB \\ A \rightarrow B \mid S \\ B \rightarrow b \mid \varepsilon \end{array}$$

2) ε -Regel

$$\begin{array}{ll} \begin{array}{l} S_0 \rightarrow S \\ S \rightarrow ASA \mid aB \mid a \\ A \rightarrow B \mid \varepsilon \mid S \\ B \rightarrow b \end{array} & \rightsquigarrow \begin{array}{l} S_0 \rightarrow S \\ S \rightarrow ASA \mid SA \mid AS \mid aB \mid a \\ A \rightarrow B \mid S \\ B \rightarrow b \end{array} \end{array}$$

3) Unit-Regel

$$\begin{array}{ll} \begin{array}{l} S_0 \rightarrow ASA \mid SA \mid AS \mid aB \mid a \\ S \rightarrow ASA \mid SA \mid AS \mid aB \mid a \\ A \rightarrow B \mid ASA \mid SA \mid AS \mid aB \mid a \\ B \rightarrow b \end{array} & \rightsquigarrow \begin{array}{l} S_0 \rightarrow ASA \mid SA \mid AS \mid aB \mid a \\ S \rightarrow ASA \mid SA \mid AS \mid aB \mid a \\ A \rightarrow b \mid ASA \mid SA \mid AS \mid aB \mid a \\ B \rightarrow b \end{array} \end{array}$$

4) Komplexe Regeln

$$S_0 \rightarrow AA_1 \mid SA \mid AS \mid UB \mid a$$

$$\begin{aligned}
 S &\rightarrow AA_1 \mid SA \mid AS \mid UB \mid a \\
 A &\rightarrow b \mid AA_1 \mid SA \mid AS \mid UB \mid a \\
 A_1 &\rightarrow SA \\
 U &\rightarrow a \\
 B &\rightarrow b
 \end{aligned}$$

4.11.7. Cocke-Younger-Kasami Algorithmus (CYK)

Gegeben

- 1) Grammatik $G = (V, \Sigma, R, S)$
- 2) Variable $A \in V$
- 3) Wort $w \in \Sigma^*$

Frage

Ist w ableitbar? in Zeichen $A \Rightarrow^* w$

- Spezialfall $w = \varepsilon$: $A \Rightarrow^* \varepsilon \Leftrightarrow A \rightarrow \varepsilon \in R$ (Epsilonregel, $A = S$)
- Spezialfall $|w| = 1$: $A \Rightarrow^* w \Leftrightarrow A \rightarrow w \in R$ (Terminalsymbolregel)
- Fall $|w| > 1$:

$$A \Rightarrow^* w \Rightarrow \exists \left\{ \begin{array}{l} A \rightarrow BC \in R \\ w = w_1 w_2 \\ w_i \in \Sigma^* \end{array} \right. \text{ mit } \left\{ \begin{array}{l} B \Rightarrow^* w_1 \\ C \Rightarrow^* w_2 \end{array} \right.$$

4.11.7.1. Ableitungsdreieck

Ideen

- Parse Tree aus $A \rightarrow BC$ und $T \rightarrow t$
- Variablen in Tabelle füllen

Prinzip

- Einem Teilwort entspricht ein Feld der Tabelle (rot hinterlegt)
- Das Feld wird mit den Variablen gefüllt, aus denen das Teilwort abgeleitet werden kann.


Beispiel

Parse des Wortes $() [()]$

$$\begin{array}{ll}
 S \rightarrow AB \mid CD \mid CU \mid SS & B \rightarrow) \\
 U \rightarrow SD & C \rightarrow [\\
 A \rightarrow (& D \rightarrow]
 \end{array}$$

Definitionen

Die Felder (k, l_1) und $(k + l_1, l - l_1)$ heissen **korrespondierende Felder** im Ableitungsdreieck des Feldes (k, l) .



5. STACK

Unendlich grosser Speicher

- Immer nur das oberste Element sichtbar
- Beliebig tief

5.1. STACKAUTOMAT / PUSHDOWN AUTOMATON (PDA)

Kann Sprachen akzeptieren, die nicht regulär sind, ist aber meistens nicht deterministisch.

Definition


Stackautomat $P = (Q, \Sigma, \Gamma, \delta, q_0, F)$

- 1) Q : Zustände
- 2) Σ : Eingabe-Alphabet
- 3) Γ : Stack-Alphabet
- 4) $\delta: Q \times \Sigma_\epsilon \times \Gamma_\epsilon \rightarrow P(Q \times \Gamma_\epsilon)$
- 5) $q_0 \in Q$: Startzustand
- 6) $F \subset Q$: Akzeptierzustände

Beachte

- immer nicht-deterministisch
- $\Gamma \neq \Sigma$ möglich

Übergänge



a vom Input


b vom Stack entfernen (Bedingung)

c auf den Stack

TODO:

finish

Beispiel 10: Stackautomat für die Sprache $\{0^n 1^n \mid n \geq 0\}$



TODO:

Book 167-168, shift/reduce

TODO:

diagrams? (slides 8/12)

5.1.1. Ableitung aus CNF

Ist L eine kontextfreie Sprache, dann gibt es einen Stackautomaten P , der L akzeptiert, $L = L(P)$.

Grundgerüst



Regel $A \rightarrow BC$	Regel $A \rightarrow a$	Regel $S \rightarrow \varepsilon$	$\forall a \in \Sigma$

5.1.2. PDA $\rightarrow$ CFG

Variablen

Wörter beschreiben Pfade durch den Automaten: Variable A_{pq} = Wörter, die von p nach q führen mit leerem Stack


Regeln

Regeln beschreiben, wie sich Wege zerlegen lassen: $A_{pq} \rightarrow A_{pr}A_{rq}$


«Wege von p nach q können verstanden werden als Wege von p nach r und von dort nach q »

5.1.2.1. Stackautomat standardisieren


1) Nur ein Akzeptierzustand: neuer Akzeptierzustand q_a und Übergänge



2) Stack leeren



3) Jeder Übergang legt entweder ein Zeichen auf den Stack oder entfernt eines



5.1.2.1.1. Regeln

TODO:

slides

TODO:

Book 182,183

Beispiel 11


TODO:

visualization

5.1.2.1.2. Grammatik ablesen

Ausgangspunkt: standardisierter PDA mit Startzustand q_0 und $F = \{q_a\}$.

- 1) Startvariable: A_{q_0, q_a}
- 2) Regeln:



Beispiel 12

TODO:

5.1.2.2. Pumping Lemma

Pumping Lemma für CFL


Ist L eine CFL, dann gibt es eine Zahl N , die Pumping Length, derart, dass jedes Wort $w \in L$ mit $|w| \geq N$ zerlegt werden kann in fünf Teile $w = uvxyz$ derart, dass

- 1) $|vy| > 0$
- 2) $|vxy| \leq N$
- 3) $uv^kxy^kz \in L \forall k \in \mathbb{N}$

Mit dem Pumping Lemma kann man beweisen, dass eine Sprache **nicht** kontextfrei ist.

Beispiel 13: $\{a^n b^n c^n \mid n \geq 0\}$

- 1) Annahme: L kontextfrei
- 2) Pumping length N
- 3) Wort: $w = a^N b^N c^N$
- 4) Zerlegungen:



- 5) Beim Pumpen nimmt die Anzahl der a und b zu, nicht aber die Anzahl der c
 $\Rightarrow uv^kxy^kz \notin L \forall k \neq 1$
- 6) Widerspruch: L nicht kontextfrei

5.1.2.2.1. Herleitung

Grammatik G in CNF

$$w \in L(G) \Rightarrow S \overset{*}{\Rightarrow} w$$

Wiederverwendete Variable

$|w| \geq N$ gross genug $\Rightarrow$ Variablen werden im Parse Tree wiederverwendet Die «unterste» wiederverwendete Variable A erzeugt zwei Wörter:

$$\begin{aligned} A &\overset{*}{\Rightarrow} uxy \\ A &\overset{*}{\Rightarrow} x \end{aligned}$$

Pumpen

$A \overset{*}{\Rightarrow} uxy$ anstelle des «untersten» $A \overset{*}{\Rightarrow} x$ verwenden

TODO:
diagram

6. PARSING

6.1. BACKUS-NAUR-FORM (BNF)

Spezifikation der Regeln in maschinen-lesbarer Form:

- Variablen: **<variablen-name>**
- Einzelne Zeichen: A
- Zeichenketten: 'BEISPIEL'
- Regeln: **<variablen-name> ::= Ausdruck**
- Ausdrücke sind Folgen von Variablen, einzelnen Zeichen oder Zeichenketten, getrennt durch $|$

Beispiel 14 : BNF für Expression-Term-Factor Grammatik

Ausgangsgrammatik

```
expression → expression + term | term
term → term * factor | factor
factor → (expression) | N
N → NZ | Z
Z → 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
```

Backus-Naur-Form

```
<expression> ::= <expression> + <term> | <term>
<term> ::= <term> * <factor> | <factor>
<factor> ::= ( <expression> ) | <number>
<number> ::= <number> <digit> | <digit>
<digit> ::= 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
```

6.2. EXTENDED BACKUS-NAUR-FORM (EBNF)

Definition

- Literale in Anführungszeichen oder Apostroph
- = statt ::=
- Variablen ohne < und >, dürfen Leerzeichen enthalten
- Komma für Verkettung ,
- Regel-Endzeichen ;
- Kommentare (* ... *)
- Optionale Wiederholung { ... }
- Option [...]
- Gruppierung (...)
- Ausnahme: -

Achtung!

- Keine Operatorpriorisierung
- Zweideutig!
- Keine eindeutige Evaluation!

Beispiel 15: EBNF für Expression-Term-Factor Grammatik

```
expression = expression, "+", term | term ;
term       = term, "*", factor, | factor ;
factor     = "(", expression, ")" | number ;
number     = digit, { digit } ;
digit      = "0" | "1" | "2" | "3" | "4" |
            "5" | "6" | "7" | "8" | "9" ;
```

6.3. RECHTSREKURSION

Expression-Term-Factor-Grammatik verwendet Links-Rekursion $\Rightarrow$ korrekte Auswertung von links nach rechts. Parsetree wertet aber Ausdrücke von rechts nach links aus! Alternative Expression-Term-Factor definition mit Rechtsrekursion statt Linksrekursion:

$$\begin{aligned} \text{expression} &\rightarrow \text{term expression}' \\ \text{expression}' &\rightarrow + \text{term expression}' \mid \epsilon \\ \text{term} &\rightarrow \text{factor term}' \\ \text{term}' &\rightarrow * \text{factor term}' \mid \epsilon \\ \text{factor} &\rightarrow (\text{expression}) \mid N \\ N &\rightarrow NZ \mid Z \\ Z &\rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9 \end{aligned}$$

TODO:

grid $\rightarrow$ table

7. UNENDLICH

Begriff

Abzählbar unendlich

Bedeutung

Eine Menge A heisst **abzählbar unendlich**, wenn es eine Bijektion $\mathbb{N} \rightarrow A$ gibt, also $A \simeq \mathbb{N}$. Bsp: $\mathbb{R}, \mathbb{Z}, \mathbb{Q}$

Begriff	Bedeutung
Überabzählbar unendlich	Eine Menge A heisst überabzählbar unendlich , wenn sie nicht abzählbar unendlich ist. Bsp: $\mathbb{R}, \mathbb{C}, P(\mathbb{N})$
Gleich mächtig	Mengen A und B heissen gleich mächtig , $A \simeq B$, wenn es eine Bijektion $A \rightarrow B$ gibt
Unendlich	Eine Menge A heisst unendlich , wenn sie gleich mächtig wie eine Teilmenge ist

A, B, A_k abzählbar unendlich, $k \in \mathbb{N}$:

1) $A \cup B, \bigcup_k A_k$ abzählbar unendlich

2) $A \times B$ abzählbar unendlich

3) Abzählbar unendlich: $\mathbb{N}, \mathbb{Z}, \mathbb{Q}$

4) $P(A)$ überabzählbar unendlich

5) $\mathbb{R}$ überabzählbar unendlich

– Abzählbar unendlich: Σ^* , Menge aller DEAs/NEAs/PDAs/CFGs

– Überabzählbar unendlich: Menge aller Sprachen $P(\Sigma^*)$

TODO:

Credits: Prof. Dr. Andreas Müller