

Wahrscheinlichkeitsrechnung und Statistik | WrStat

Zusammenfassung

INHALTSVERZEICHNIS

1. Kombinatorik	2
1.1. Zählregeln	2
1.2. Erzeugende Funktion	2
2. Wahrscheinlichkeit	3
2.1. Experimente und Ereignisse	3
2.1.1. Ereignis-Algebra	3
2.1.2. Wahrscheinlichkeit	4
2.1.3. Bedingte Wahrscheinlichkeit	4
2.1.4. Monty-Hall-Problem	5
2.2. Übergangsmatrix / Markov-Kette	5
2.2.1. Google page rank	7
2.2.2. Stationäre Verteilung	7
2.3. Zufallsvariablen	8
2.4. Erwartungswert	8
2.4.1. Unabhängigkeit	9
2.4.2. Varianz	9

1. KOMBINATORIK

Mathematische Disziplin, die sich mit der Frage befasst, wie viele (und welche) Möglichkeiten es gibt, eine bestimmte Anzahl von Dingen auszuwählen und miteinander zu kombinieren.

1.1. ZÄHLREGELN

TODO:

merge with DigCod and MathFML

TODO:

Hypergeometrische Verteilung

Disjunkte Vereinigung: $|A \cup B| = |A| + |B|$

Schnittmenge: $|A \cup B| = |A| + |B| - |A \cap B|$

Paare/Produkt: $|A \times B| = |A| \cdot |B|$

Permutation: Auf wieviele Arten kann man n Objekte anordnen?

$$P_n = n!$$

Kombination: Auf wieviele Arten kann man k Objekte aus n auswählen?

$$C_k^n = \binom{n}{k}$$

Variation: Auf wieviele Arten kann man k mal unter n verschiedenen Objekten auswählen?

$$V_k^n = n^k$$

Binomische Formel:

$$(a + b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$$

1.2. ERZEUGENDE FUNKTION

Oftmals lassen sich schwierige kombinatorische Fragestellungen in algebraische oder analytische Probleme umformulieren. Damit steht dann der Apparat der Analysis zur Verfügung.

Die Zahlen $a_0, a_1, a_2, \dots, a_n$ kann man wie folgt in ein **erzeugende Funktion** codieren:

$$f(z) = a_0 + a_1 z + a_2 z^2 + a_3 z^3 + \dots$$

Für den Platzhalter z soll gar kein Zahlenwert substituiert werden. Vielmehr dienen die Potenzen z_k nur dazu, die einzelnen Zahlen a_k auseinander zu halten. Man spricht von einer **formalen Potenzreihe**.

Beispiel 1: Kombination

Die Koeffizienten dieses Polynoms geben an, **auf wie viele Arten** man k Elemente aus einer n -elementigen Menge auswählen kann.

$$p_n(z) = (1+z)^n = \sum_{k=1}^n \binom{n}{k} z^k \Rightarrow C_k^n = \binom{n}{k}$$

TODO:

2. WAHRSCHEINLICHKEIT

2.1. EXPERIMENTE UND EREIGNISSE

Elementarereignis: Der Ausgang eines Experiments heisst **Elementarereignis** ω .

Experiment: Menge der möglichen Versuchsausgänge/Elementarereignisse: $\Omega, \omega \in \Omega$.

Ereignis: Teilmengen von Ω heissen **Ereignisse**. A eingetreten $\Leftrightarrow \omega \in A$, B nicht eingetreten $\Leftrightarrow \omega \notin B$

Versuch: Einzelne Durchführung eines Zufallsexperiments

Das Sichere Ereignis: $A = \Omega \subset \Omega$, A tritt immer ein

Das Unmögliche Ereignis: $B = \emptyset = \{\} \subset \Omega$, B tritt nie ein

2.1.1. Ereignis-Algebra

Eine Ereignis-Algebra ist eine Menge $\mathcal{A}$ von Ereignissen derart, dass gilt:

1) Mit zwei Ereignissen $A, B \in \mathcal{A}$ ist auch die Vereinigung ein Ereignis:

$$A, B \in \mathcal{A} \Rightarrow A \cup B \in \mathcal{A}$$

2) Mit zwei Ereignissen $A, B \in \mathcal{A}$ ist auch die Differenz ein Ereignis:

$$A, B \in \mathcal{A} \Rightarrow A \setminus B \in \mathcal{A}$$

3) Es gibt das sichere Ereignis:

$$\Omega \in \mathcal{A}$$

Begriff	Modell
Ereignis ist eingetreten	$\omega \in A$
A und B treten ein	$A \cap B$
A oder B treten ein	$A \cup B$
A aber nicht B	$A \setminus B$
A hat B zur Folge, wenn A dann auch B	$A \subset B$
nicht A	$\overline{A} = \Omega \setminus A$

Daraus folgt:

1) Es gibt das unmögliche Ereignis

$$\emptyset = \Omega \setminus \Omega \in \mathcal{A}$$

2) Das Komplement eines Ereignisses ist ebenfalls ein Ereignis

$$A \in \mathcal{A} \Rightarrow \overline{A} = \Omega \setminus A \in \mathcal{A}$$

3) Die Schnittmenge zweier Ereignisse ist ebenfalls ein Ereignis:

$$A, B \in \mathcal{A} \Rightarrow A \cap B = (A \cup B) \setminus ((A \setminus B) \cup (B \setminus A)) \in \mathcal{A}$$

Rechenregeln

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

$$\overline{A \cap B} = \overline{A} \cup \overline{B}$$

$$\overline{A \cup B} = \overline{A} \cap \overline{B}$$

2.1.2. Wahrscheinlichkeit

Die Wahrscheinlichkeit eines Ereignisses $A \subset \Omega$ ist eine Zahl

$$P(A) = \lim_{n \rightarrow \infty} \frac{\text{Anzahl Eintreten von } A}{\text{Anzahl } n \text{ Versuche}} = \lim_{n \rightarrow \infty} \text{rel. Häufigkeit von } A$$

mit den folgenden Eigenschaften:

1) Wertebereich:

$$0 \leq P(A) \leq 1$$

2) Wahrscheinlichkeit des sicheren Ereignisses:

$$P(\Omega) = 1$$

3) Disjunkte Vereinigung: Sind die Ereignisse A_i disjunkt, also $A_j \cap A_i = \emptyset$ für $i \neq j$, dann gilt

$$P(A_1 \cup A_2 \cup \dots \cup A_n \cup \dots) = P(A_1) + P(A_2) + \dots + P(A_n) + \dots$$

Daraus folgt:

1) Wahrscheinlichkeit des unmöglichen Ereignisses:

$$P(\emptyset) = 0$$

Aber: auch nichtleere Ereignisse können Wahrscheinlichkeit 0 haben!

2) Wahrscheinlichkeit des komplementären Ereignisses

$$P(\overline{A}) = P(\Omega \setminus A) = 1 - P(A)$$

3) Wahrscheinlichkeit der Differenz zweier Ereignisse A und B

$$P(A \setminus B) = P(A) - P(A \cap B)$$

4) Wahrscheinlichkeit der Vereinigung zweier beliebiger Ereignisse

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Laplace-Experiment: Alle Versuchsausgänge haben die gleiche Wahrscheinlichkeit

$$P(A) = \frac{\text{Anzahl günstige Ausgänge}}{\text{Anzahl mögliche Ausgänge}} = \frac{|A|}{|\Omega|}$$

Bernoulli-Experiment: Genau zwei Versuchsausgänge mit Wahrscheinlichkeiten p und $1 - p$.

$$p = P(A), 1 - p = 1 - P(A) = P(\overline{A})$$

2.1.3. Bedingte Wahrscheinlichkeit

Bedingte Wahrscheinlichkeit: Wahrscheinlichkeit für A , wenn B bereits eingetreten ist:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Unabhängigkeit: A und B heißen **unabhängig**, wenn:

$$\begin{aligned} P(A \cap B) &= P(A) \cdot P(B) \\ \Leftrightarrow P(A|B) &= P(A|\overline{B}) \\ \Leftrightarrow P(A|B) &= P(A) \end{aligned}$$

Abhängigkeit: A und B heißen **Abhängig**, wenn:

$$P(A|B) < P(A|\overline{B})$$

Bayes-Theorem: Im Allgemeinen ist $P(A|B) \neq P(B|A)$

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Totale Wahrscheinlichkeit:

$$P(A) = P(A|B_1)P(B_1) + \dots + P(A|B_n)P(B_n)$$

wenn B_i disjunkt und $\bigcup_{B_i} = \Omega$ (die B_i müssen alles abdecken)

2.1.4. Monty-Hall-Problem

Es gibt drei Türen. Hinter einer ist ein Auto, hinter den anderen beiden eine Ziege.

- 1) Spieler wählt eine Tür (erste Wahl).
- 2) Spielleiter öffnet eine Tür, hinter der sich eine Ziege verbirgt.
- 3) Spieler kann bei der Wahl bleiben oder die Tür wechseln.

Ereignisse:

$$\begin{aligned} \Omega &= \{\text{Alle Spielverläufe}\} & P(Z) &= \frac{2}{3} \\ Z &= \{\text{Erste Wahl ist eine Ziege}\} \\ A &= \{\text{Erste Wahl ist ein Auto}\} & P(A) &= \frac{1}{3} \\ G &= \{\text{Gewinnt ein Auto}\} \end{aligned}$$

Spielstrategien:

- 1) Wechselstrategie: Auf die verbleibende, nicht geöffnete Tür wechseln.

$$\begin{aligned} P(G|A) &= 0 \quad P(G|Z) = 1 \\ P(G) &= P(G|A) \cdot P(A) + P(G|Z) \cdot P(Z) \\ &= 0 \cdot P(A) + 1 \cdot P(Z) \\ &= P(Z) = \frac{2}{3} \end{aligned}$$

- 2) Bleibestrategie: Bei der Tür der ersten Wahl bleiben.

$$\begin{aligned} P(G|A) &= 1 \quad P(G|Z) = 0 \\ P(G) &= P(G|A) \cdot P(A) + P(G|Z) \cdot P(Z) \\ &= 1 \cdot P(A) + 0 \cdot P(Z) \\ &= P(A) = \frac{1}{3} \end{aligned}$$

2.2. ÜBERGANGSMATRIX / MARKOV-KETTE

Eine **homogene** Markov-Kette ist eine **zeitunabhängige** Übergangsmatrix T

Zustände:

$$S = \{0, 1, 2, 3, \dots\}$$

Ereignisse:

$$S_j = \{\text{Zustand } j \text{ vor Übergang}\}$$

$$S'_i = \{\text{Zustand } i \text{ nach Übergang}\}$$

Übergänge: Wahrscheinlichkeit für den Übergang $j \rightarrow i$

$$t_{ij} = P(S'_i | S_j)$$

Übergangsmatrix:

$$\begin{aligned} T &= (t_{ij}) \\ &= \begin{pmatrix} P(S'_1 | S_1) & \dots & P(S'_1 | S_N) \\ \vdots & \ddots & \vdots \\ P(S'_N | S_1) & \dots & P(S'_N | S_N) \end{pmatrix} \end{aligned}$$

Verteilung vorher/nachher:

$$p = \begin{pmatrix} P(S_0) \\ P(S_1) \\ \vdots \\ P(S_N) \end{pmatrix}, \quad p' = \begin{pmatrix} P(S'_0) \\ P(S'_1) \\ \vdots \\ P(S'_N) \end{pmatrix}$$

Totale Wahrscheinlichkeit:

$$\begin{aligned} P(S'_i) &= \sum_{k \in S} P(S'_i | S_k) P(S_k) \\ p'_i &= \sum_{k \in S} T_{ik} p_k \\ \begin{pmatrix} P(S'_1) \\ \vdots \\ P(S'_N) \end{pmatrix} &= \begin{pmatrix} P(S'_1 | S_1) & \dots & P(S'_1 | S_N) \\ \vdots & \ddots & \vdots \\ P(S'_N | S_1) & \dots & P(S'_N | S_N) \end{pmatrix} \begin{pmatrix} P(S_1) \\ \vdots \\ P(S_N) \end{pmatrix} \end{aligned}$$

Stationäre Verteilung: Der Eigenvektor zum Eigenwert 1 einer Übergangsmatrix ist die stationäre Verteilung der Markov-Kette. Er wird berechnet, weil er die langfristige, unveränderliche Wahrscheinlichkeit über die Zustände liefert

$$p' = Tp$$

Nach n Zeitschritten: $p(t)$ Verteilung zur Zeit t : $p(t+n) = T^n p(t)$

Beispiel 2: Weblinks

Angenommen alle Übergänge und Initialzustände sind gleich wahrscheinlich:

$$S_i = \{\text{Besucher auf Seite } i\}$$


$$S'_j = \{\text{Besucher nach Navigation auf Seite } i\}$$

Markov-Kette

$$T = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 1 \\ \frac{1}{2} & 0 & \frac{1}{2} & \frac{1}{3} & 0 & 0 \\ \frac{1}{2} & 0 & 0 & \frac{1}{3} & 0 & 0 \\ 0 & 1 & 0 & 0 & \frac{1}{2} & 0 \\ 0 & 0 & \frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{3} & \frac{1}{2} & 0 \end{pmatrix}$$

$$P(S'_j) = P(S'_j|S_1)P(S_1) + P(S'_j|S_2)P(S_2) + \dots + P(S'_j|S_N)P(S_N)$$

$$P(S'_1) = 0 + 0 + 0 + 0 + 0 + 1 \cdot \frac{1}{6} = \frac{1}{6}$$



2.2.1. Google page rank

$$G = \alpha H + \frac{1-\alpha}{N} A$$

heisst **Google-Matrix**, wobei

$$H = \begin{pmatrix} P(S'_1|S_1) & \dots & P(S'_1|S_N) \\ \vdots & \ddots & \vdots \\ P(S'_N|S_1) & \dots & P(S'_N|S_N) \end{pmatrix}$$

$$A = \begin{pmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{pmatrix}$$

und α der «Freie Wille» ist, also wie oft der Surfer einem link folgt. $\alpha = 1 \Rightarrow$ Surfer klickt immer einen link, $\alpha = 0 \Rightarrow$ der Surfer «Teleportiert» immer zur Seite durch «Freien Willen».

Der Pagerank Vektor p ist der Eigenvektor von G zum Eigenwert 1:

$$Gp = p = \lim_{n \rightarrow \infty} G^n p_0$$

wobei p_0 ein geeigneter Startvektor.

TODO:

Potenzmethode

2.2.2. Stationäre Verteilung

Stationär: Die Verteilung p heisst **stationär**, wenn sie sich mit der Zeit nicht ändert: $Tp = p$.

Grenzverteilung: p heisst **Grenzverteilung**, wenn $\lim_{n \rightarrow \infty} T^n p_0 = p$ für eine Startverteilung $p_0 \Rightarrow$ Grenzverteilungen sind stationär

Daraus folgt, dass eine Stationäre Verteilung als Eigenvektor von T existiert.

Perron-Frobenius-Theorie: Die Übergangsmatrix T ist **nichtnegativ**, d. h.

$$T \geq 0 \Leftrightarrow t_{ij} \geq 0 \quad \forall i, j$$

und die Totalen Wahrscheinlichkeiten summieren immer zu 1:

$$\sum_j P(S'_i | S_j) = \sum_i t_{ij} = 1 \quad \forall j$$

Satz von Perron-Frobenius: Eine irreduzible Wahrscheinlichkeitsmatrix hat einen einzigen positiven EV zum EW 1: $Tp = p$

2.3. ZUFALLSVARIABLEN

Eine Zufallsvariable X ist eine Funktion $X : \Omega \rightarrow \mathbb{R}$, die einem Versuchsausgang ω einen Wert $X(\omega)$ zuordnet.

Man beachte: die Zufälligkeit liegt in dem Versuch, der das ω ermittelt. Die Zuweisung des Wertes $X(\omega)$ ist deterministisch.

Kürzere Schreibweise:

$$\begin{aligned} P(X = a) &= P(\{\omega \in \Omega \mid X(\omega) = a\}) \\ &= P(\{X = a\}) \end{aligned}$$

Diskrete Zufallsvariable: Eine Zufallsvariable heisst **diskret**, wenn sie nur einzelne genau bestimmte Zahlenwerte $x_1, x_2, x_3, \dots$ annehmen kann

Stetige Zufallsvariable: Eine Zufallsvariable heisst **stetig**, wenn sie beliebige Werte in einem Intervall annehmen kann (Wertemenge ist nicht diskret). $P(X = x) = 0$

2.4. ERWARTUNGSWERT

Ist X eine Zufallsvariable, dann ist der **Erwartungswert**:

$$\begin{aligned} E(X) &= \sum \text{Wert} \cdot \text{Wahrscheinlichkeit} \\ &= \sum_{\omega \in \Omega} X(\omega) \cdot P(\{\omega\}) \\ &= \sum_{i=1}^k X(A_i) \cdot P(A_i) \end{aligned}$$

wobei X konstant auf A_i und $\bigcup A_i = \Omega$ sein muss.

Der Erwartungswert ist **linear**: Sind X, Y Zufallsvariablen, dann gilt

$$\begin{aligned} E(X + Y) &= E(X) + E(Y) \\ E(\lambda X) &= \lambda E(X) \\ E(f(X)g(Y)) &= E(f(X))E(g(y)), \quad f, g : \mathbb{R} \rightarrow \mathbb{R} \end{aligned}$$

Sei $A \subset \Omega$ ein Ereignis, dann ist die charakteristische Funktion von A eine Zufallsvariable:

$$\chi_A : \Omega \rightarrow \mathbb{R}, \quad \chi_A(\omega) = \begin{cases} 1 & \omega \in A \\ 0 & \omega \notin A \end{cases}$$

Ihr Erwartungswert ist

$$\begin{aligned} E(\chi_A) &= \chi_A(A) \cdot P(A) + \chi_A(\bar{A}) \cdot P(\bar{A}) \\ &= 1 \cdot P(A) + 0 \cdot (1 - P(A)) \\ &= P(A) \end{aligned}$$

Satz: Der Erwartungswert $E(X)$ einer reellen Zufallsvariable X ist diejenige reelle Zahl μ , für die $E((X - \mu)^2)$ minimal wird.

2.4.1. Unabhängigkeit

X und Y sind unabhängig, wenn die Ereignisse $\{X \leq x\}$ und $\{Y \leq y\}$ unabhängig sind, also

$$\forall x, y \in \mathbb{R}. (P((X \leq x) \wedge (Y \leq y)) = P(X \leq x)P(Y \leq y))$$

Seien A_i, B_j Ereignisse, auf denen X bzw. Y konstant ist $\Rightarrow$ unabhängig.

$$\begin{aligned} E(XY) &= \sum_i \sum_j X(A_i \cap B_j) Y(A_i \cap B_j) P(A_i \cap B_j) \\ &= \sum_i \sum_j X(A_i) Y(B_j) P(A_i) P(B_j) \\ &= \sum_i (X(A_i) P(A_i)) \sum_j (Y(B_j) P(B_j)) \\ &= E(X) E(Y) \\ \text{cov}(X, Y) &= E(XY) - E(X) E(Y) \end{aligned}$$

Unabhängig $\Rightarrow$ unkorreliert, unkorreliert $\nRightarrow$ unabhängig

2.4.2. Varianz

Mittlere quadratische Abweichung vom Erwartungswert.


$$\begin{aligned} \text{var}(X) &= E(X - E(X))^2 \\ &= E(X^2) - E(X)^2 \end{aligned}$$

Für unabhängige Zufallsvariablen X und Y gilt:

$$\begin{aligned} \text{var}(\lambda X) &= \lambda^2 \text{var}(X) \\ \text{var}(XY) &= \text{var}(X) \text{var}(Y) + \text{var}(Y) E(X)^2 \\ &\quad + \text{var}(X) E(Y)^2 \end{aligned}$$

Für unkorrelierte Zufallsvariablen X und Y gilt:

$$\text{var}(X + Y) = \text{var}(X) + \text{var}(Y)$$



Beispiel 3: Würfel

ω	$P(\omega)$	X	X^2	$X - E(X)$	$(X - E(X))^2$
1	$1/6$	1	1	-2.5	6.25
2	$1/6$	2	4	-1.5	2.25
3	$1/6$	3	9	-0.5	0.25
4	$1/6$	4	16	0.5	0.25
5	$1/6$	5	25	1.5	2.25
6	$1/6$	6	36	2.5	6.25
		$E(X) = 21/6$	$E(X^2) = 91/6$	$\text{var}(X) = E(X^2) - E(X)^2 = 35/12$	

2.4.2.1. Empirische Varianz

Messwerte $x_1, x_2, \dots, x_n$ einer Zufallsvariable X

$$\begin{aligned}\text{var}(X) &\approx \frac{1}{n} \sum_i (x_i - \mu)^2 \\ &= E(X^2) - E(X)^2\end{aligned}$$

2.4.2.2. Ungleichung von Tschebyscheff

Selbst wenn man gar nichts über die Zufallsvariable weiss, ausser dass sie eine Varianz besitzt, kann man eine Aussage über die Wahrscheinlichkeit einer grossen Abweichung machen.

Ist eine Zufallsvariable X , dann lässt sich die Wahrscheinlichkeit, dass X um mehr als ε vom Erwartungswert abweicht, wie folgt abschätzen:


$$P(|X - \mu| > \varepsilon) \leq \frac{\text{var}(X)}{\varepsilon^2}$$

Beweis

$$A = \{\varepsilon < |X - \mu|\} = \{\varepsilon^2 < (X - \mu)^2\}$$

$$\chi_A < \frac{(X - \mu)^2}{\varepsilon^2}$$

$$P(A) \leq E\left(\frac{(X - \mu)^2}{\varepsilon^2}\right) = \frac{\text{var}(X)}{\varepsilon^2}$$



2.4.2.3. Satz von Bernoulli

Gegeben: Zufallsvariable X

Stichprobe: $X_1, \dots, X_n$ Zufallsvariablen mit gleichem Erwartungswert $\mu = E(X)$ und gleicher Varianz wie X

Mittelwert: $M_n = X_1 + \dots + X_n / n$, $E(M_n) = E(X)$, $\text{var}(M_n) = \text{var}(X) / n$

$$P(|M_n - \mu| > \varepsilon) \leq \frac{\text{var}(X)}{n\varepsilon^2}$$

$\Rightarrow$ Je mehr Messungen n , desto unwahrscheinlicher eine grosse Abweichung des Mittelwertes vom Erwartungswert.

Beispiel 4:

Ereignis: $A \subset \Omega$

Experiment: $X = \chi_A$, $P(A) = E(X)$, $\text{var}(X) = P(A) - P(A)^2 = P(A)(1 - P(A))$

Wiederholtes Experiment: $X_1, \dots, X_n$

Relative Häufigkeit: $h_n = X_1 + \dots + X_n / n$, $E(h_n) = P(A)$, $\text{var}(h_n) = \text{var}(X) / n = P(A)(1 - P(A)) / n$

$$P(|h_n - P(A)| > \varepsilon) \leq \frac{P(A)(1 - P(A))}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}$$

